EXAMEN FINAL · GRUPO 4

Detección de personas y armas en videovigilancia mediante Yolov5s

YOLOv5s · objetos pequeños · entrenamiento Multi-Scale · motor temporal

Jose Miguel Alvarado Moreno · Dina Yesica Huamán Huallpa
José Gabriel Laymito Quispe · Christopher Núñez Varillas · Frank Huaman Cancho

MAESTRÍA EN INTELIGENCIA ARTIFICIAL · UNIVERSIDAD NACIONAL DE INGENIERÍA

Problemática de la Vigilancia Automatizada y Objetos Pequeños

El Desafío de la Supervisión Continua

La vigilancia humana es insostenible ante el volumen masivo de datos. Los modelos de visión artificial actúan como herramientas críticas de apoyo para localizar eventos de interés y priorizar la revisión humana ante amenazas.

Escala Reducida

Las armas suelen ocupar una fracción mínima de la imagen (objetos pequeños), lo que dificulta extraer características semánticas precisas para el modelo.

Complejidad de Escena

Presencia de oclusiones parciales, desenfoque por movimiento y posicionamiento en zonas periféricas que complican la detección fiable.

Ambigüedad Visual

Existe una alta similitud morfológica entre armas y objetos inofensivos del entorno, aumentando el riesgo de falsas alarmas.

Detección Multiclase

El sistema se enfoca en la localización técnica de las categorías "person" (persona) y "gun" (arma) mediante el modelo YOLOv5s.

Sin Inferencia de Identidad

Se establece explícitamente que el sistema no busca identificar individuos ni inferir intenciones o comportamientos sospechosos.

Evidencia Visual

El propósito fundamental es generar alertas y evidencia visual para optimizar la toma de decisiones del operador humano.

Tres enfoques en la literatura

La propuesta integra detección por frame y filtrado temporal, pero evalúa cada componente por separado.

Detección de armas

Olmos et al. (2018): detección y alarma de pistolas.
Salazar González et al. (2020): desafíos en CCTV real.

Contexto de la escena

Velasco-Mata et al. (2021): pose humana.
Berardini et al. (2024): localización y análisis con detectores.

Objetos pequeños

Corral-Sanz et al. (2024): distorsiones visuales.
Berardini et al. (2025): superresolución.

Aporte propio: evidencia sistemática B1–M1–M2 y motor temporal en un prototipo de vigilancia.

MOTIVACIÓN

¿Por qué es difícil detectar armas en CCTV?

El reto no es solo reconocer un objeto: es localizarlo, a menudo pequeño, en escenarios complejos.

01 · Escala reducida

Un arma puede ocupar apenas una fracción del fotograma. El detalle visual disminuye con distancia y compresión.

02 · Condiciones adversas

Oclusión, movimiento, desenfoque, iluminación variable y ubicación periférica dificultan la detección.

03 · Riesgo operacional

Una falsa alarma satura al operador; una omisión puede impedir que se revise un evento relevante.

Propósito: asistir a una persona que supervisa el video; no identificar individuos ni inferir intenciones.

INVESTIGACIÓN

Pregunta central y contribuciones

¿Multi-Scale mejora la detección de armas pequeñas frente a YOLOv5s baseline con costo razonable?

01

Datos sin fuga

Partición de YouTube-GDD por secuencia de video.

02

Ablación controlada

B1 (640) → M1 (1280) → M2 (640 + Multi-Scale).

03

Diagnóstico geométrico

Errores por tamaño, periferia, densidad y anchors.

04

Aplicación

MVP Streamlit con filtrado temporal y registro de alertas.

DATOS

YouTube-GDD: curación y partición

5,000 imágenes iniciales; se excluyó un frame sin anotación válida y se evitó solapamiento entre videos.

4,999
imágenes finales

12,555
cajas anotadas

2
clases: person / gun

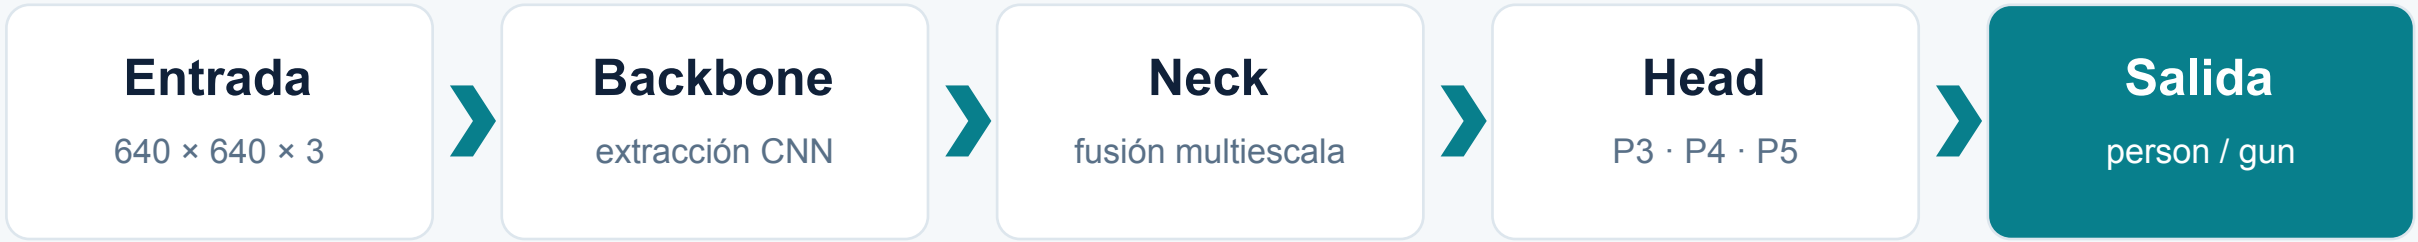
Conjunto	Imágenes	person	gun
Train	3,997	3,713	6,432
Validation	494	410	712
Test	508	400	888

Train ajusta los pesos · Validation selecciona el modelo · Test permanece reservado hasta el final

MODELO

Arquitectura YOLOv5s

Detector de una etapa, inicializado con pesos COCO y ajustado para person y gun.



Detección multiescala ≠ Multi-Scale Training

YOLOv5s ya predice en varios niveles; M2 varía dinámicamente la resolución durante el entrenamiento.

¿Por qué importa P3?

Un mapa con stride 8 conserva más detalle espacial que los niveles de stride 16 y 32.

METODOLOGÍA

Diseño experimental: una variable principal

Mismos datos, pesos iniciales, optimizador SGD, batch 16, 100 épocas y seed 0.

B1

BASELINE

640 × 640

Multi-Scale: NO

M1

RESOLUCIÓN

1280 × 1280

Multi-Scale: NO

M2

ESCALA VARIABLE

640 × 640

Multi-Scale: SÍ

Regla de selección: elegir el mejor checkpoint exclusivamente con Validation; después evaluar una sola vez en Test.

EXPERIMENTO 1

B1: buen resultado global, problemas en gun

La línea base termina 100 épocas; el mejor checkpoint corresponde a la época 84.

0.852

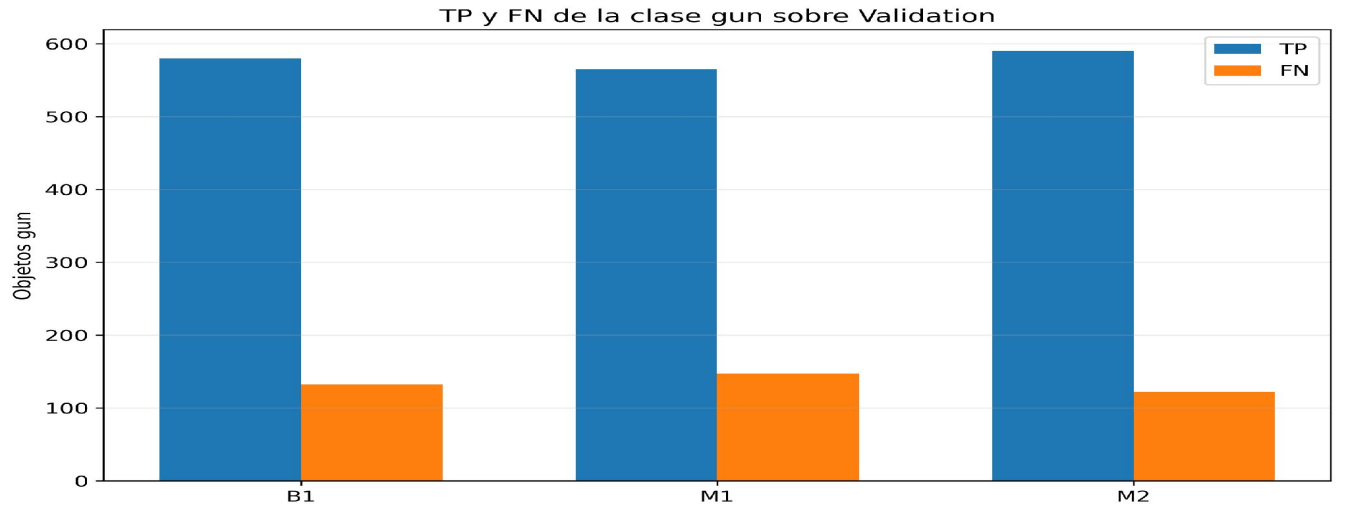
mAP@0.5 · Validation

0.669

mAP@0.5:0.95

132

gun no detectados (FN diagnóstico)



Hallazgo

La mediana de área de gun FN fue 0.005678 frente a 0.178150 para TP: los errores se concentran en objetos pequeños.

EXPERIMENTO 2

M1: duplicar resolución no garantizó mejorar

1280×1280 elevó el costo de entrenamiento y empeoró las métricas de Validation.

−0.061

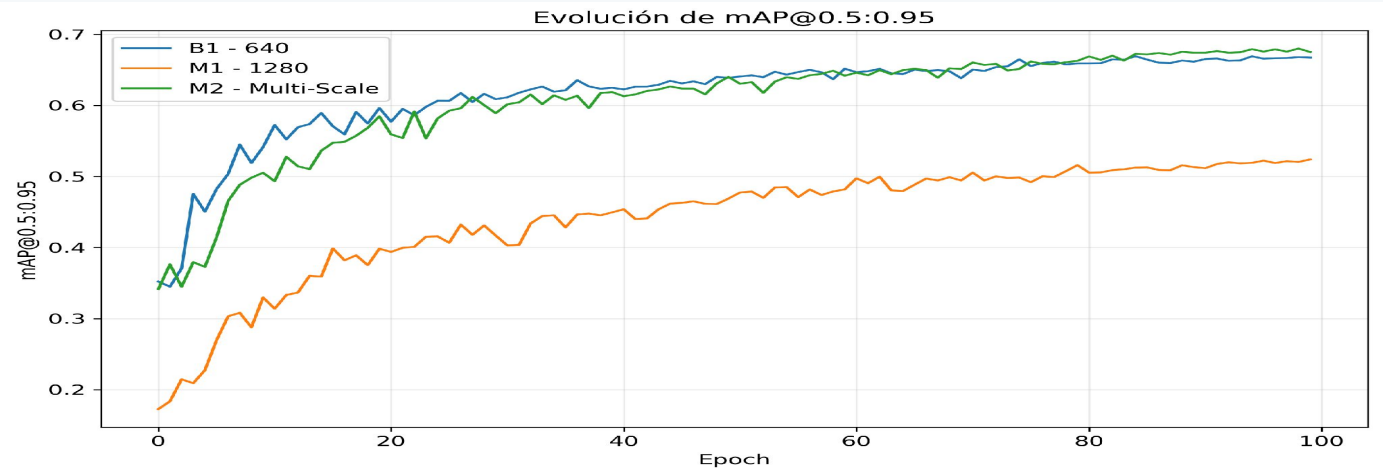
Δ mAP@0.5 frente a B1

+75.9%

tiempo de entrenamiento

147

FN gun (B1 tenía 132)

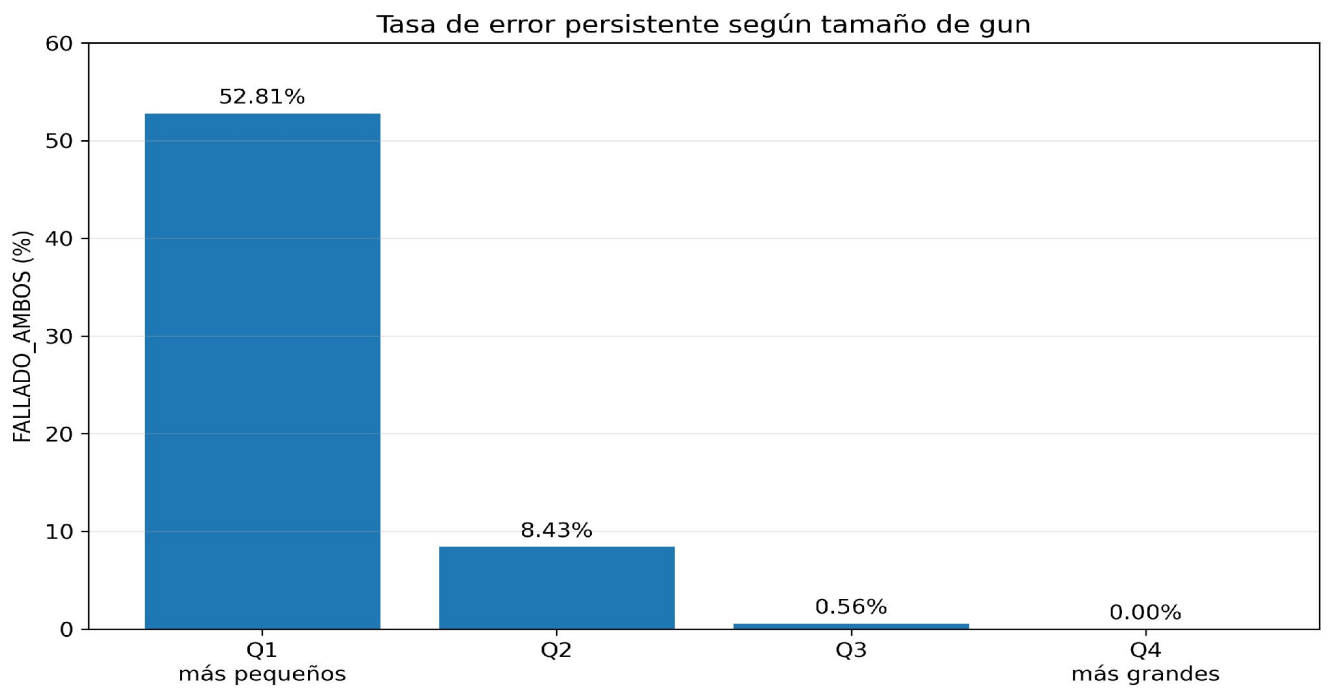


Prueba por objeto

22 armas recuperadas por M1, pero 37 perdidas frente a B1. Balance neto: 15 detecciones menos.

¿Dónde fallaban B1 y M1?

Se analizaron los 110 objetos gun no detectados por ninguno de los dos modelos.



94 de 110

fallos persistentes estaban en el cuartil de menor área (Q1).

80%

de los objetos fallados por ambos estaban en regiones periféricas.

102 de 110

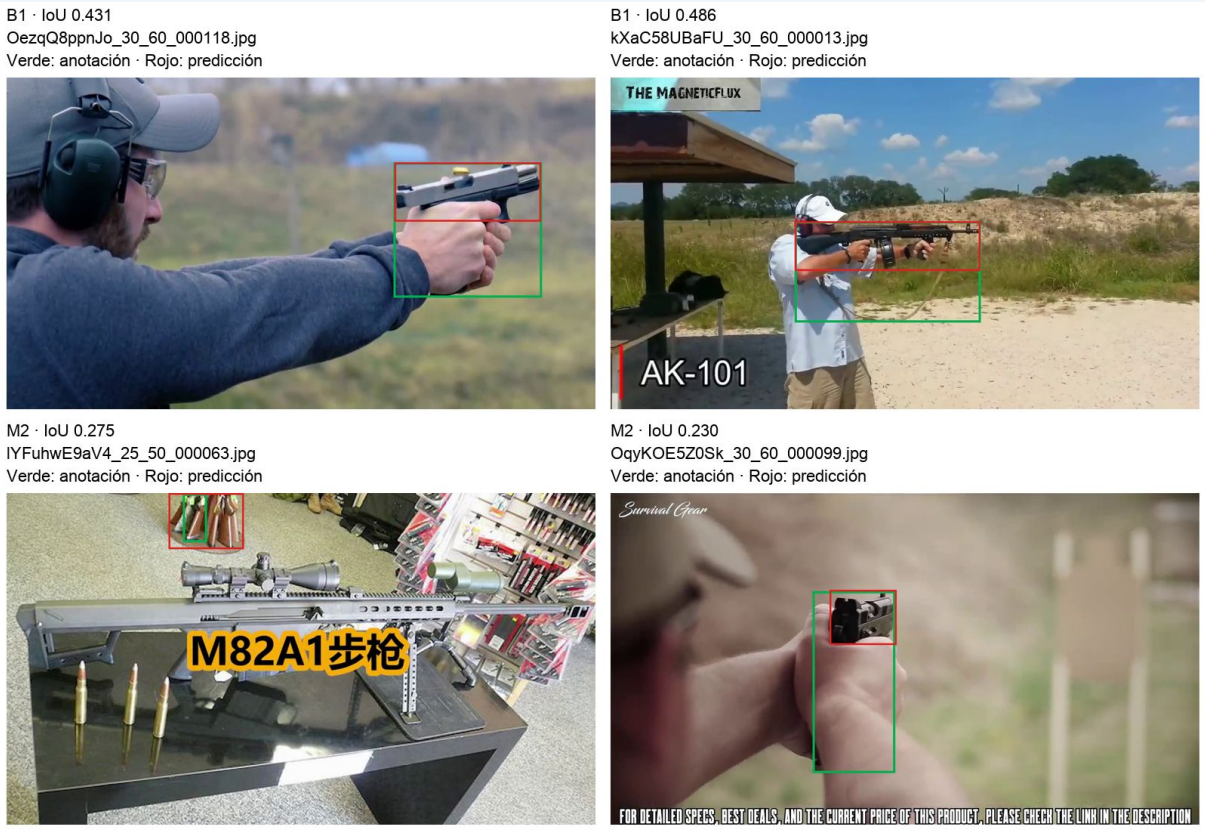
ocurrieron en imágenes con más de un arma.

La evidencia orientó la nueva hipótesis: aprender variaciones de escala, no solo usar más píxeles.

EVIDENCIA VISUAL

Casos reales: aciertos y errores de localización

Ejemplos procedentes de results/workstation/grupo; representan evidencia cualitativa, no una nueva evaluación.



¿Qué muestran?

- Armas que ocupan pocos píxeles.
- Diferencias de localización.
- Objetos parcialmente ocluidos.
- Ejemplos con distintos contextos visuales.

Fuente: ejemplos visuales del repositorio experimental.

Anchors y representatividad del entrenamiento

La causa no parecía ser una incompatibilidad geométrica general con los anchors.

0.608
mejor anchor IoU mediano · fallados

0.574
mejor anchor IoU mediano · detectados

72.73%
hard gun con patrón pequeño + periférico + denso

Decisión experimental

No se modificaron los anchors: se eligió variar la escala en el entrenamiento de M2 para explorar robustez con costo comparable a B1.

EXPERIMENTO 3

M2: Multi-Scale mejoró de forma moderada

M2 mantuvo resolución nominal 640×640 y obtuvo el mejor fitness en Validation.

0.6983

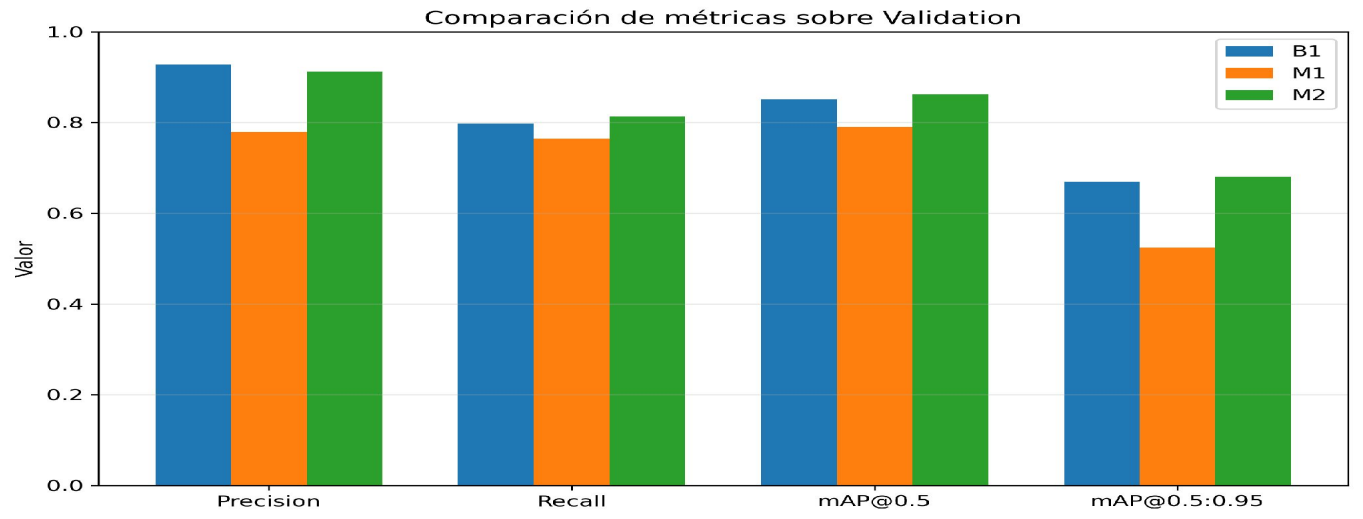
fitness de M2

122

FN gun · antes 132

1.837 h

entrenamiento · B1 1.823 h



Cambio frente a B1

Recall: +0.0145.
mAP@0.5: +0.0103.
mAP@0.5:0.95: +0.0108.

COMPARACIÓN

Resultado principal de las tres configuraciones

Todas las métricas corresponden al conjunto Validation, no a Test.

Métrica	B1 · 640	M1 · 1280	M2 · Multi-Scale
Precision	0.9284	0.7792	0.9128
Recall	0.7984	0.7641	0.8129
mAP@0.5	0.8516	0.7903	0.8619
mAP@0.5:0.95	0.6694	0.5240	0.6802
Fitness	0.6876	0.5507	0.6983
FN gun	132	147	122
GPU-h	1.823	3.206	1.837

M2 · MODELO SELECCIONADO

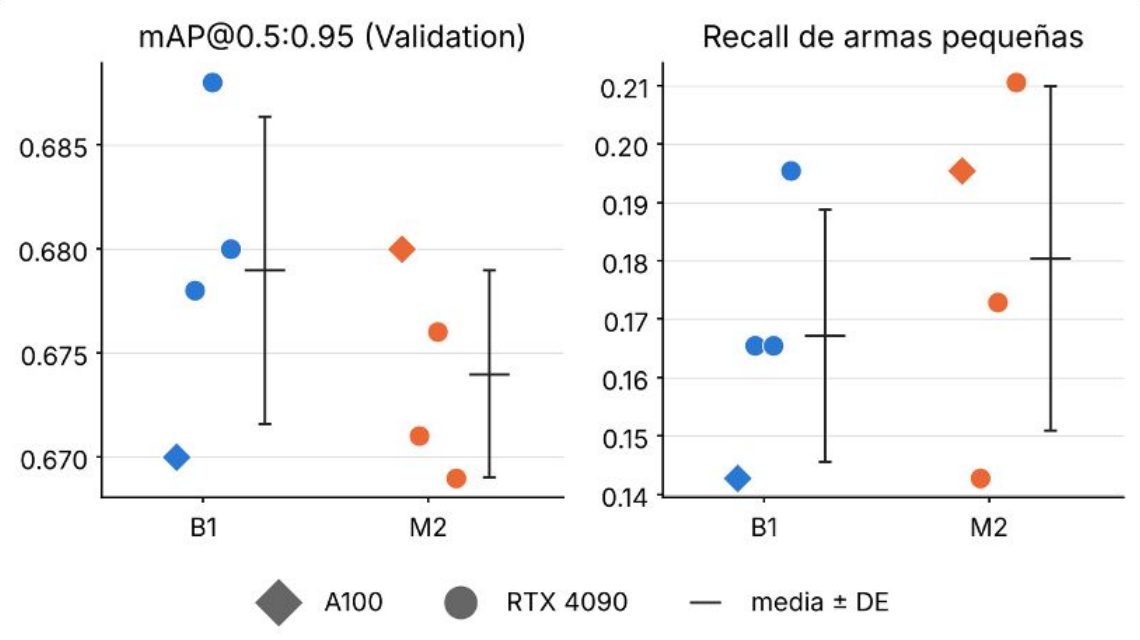
Con cuatro entrenamientos, B1 y M2 no se distinguen

B1 y M2 repetidos con semillas 0, 1 y 2 en RTX 4090, más la corrida inicial en A100.

0.679 ± 0.007
mAP@0.5:0.95 · B1 (4 corridas)

0.674 ± 0.005
mAP@0.5:0.95 · M2 (4 corridas)

p = 0.31
permutación exacta · sin diferencia

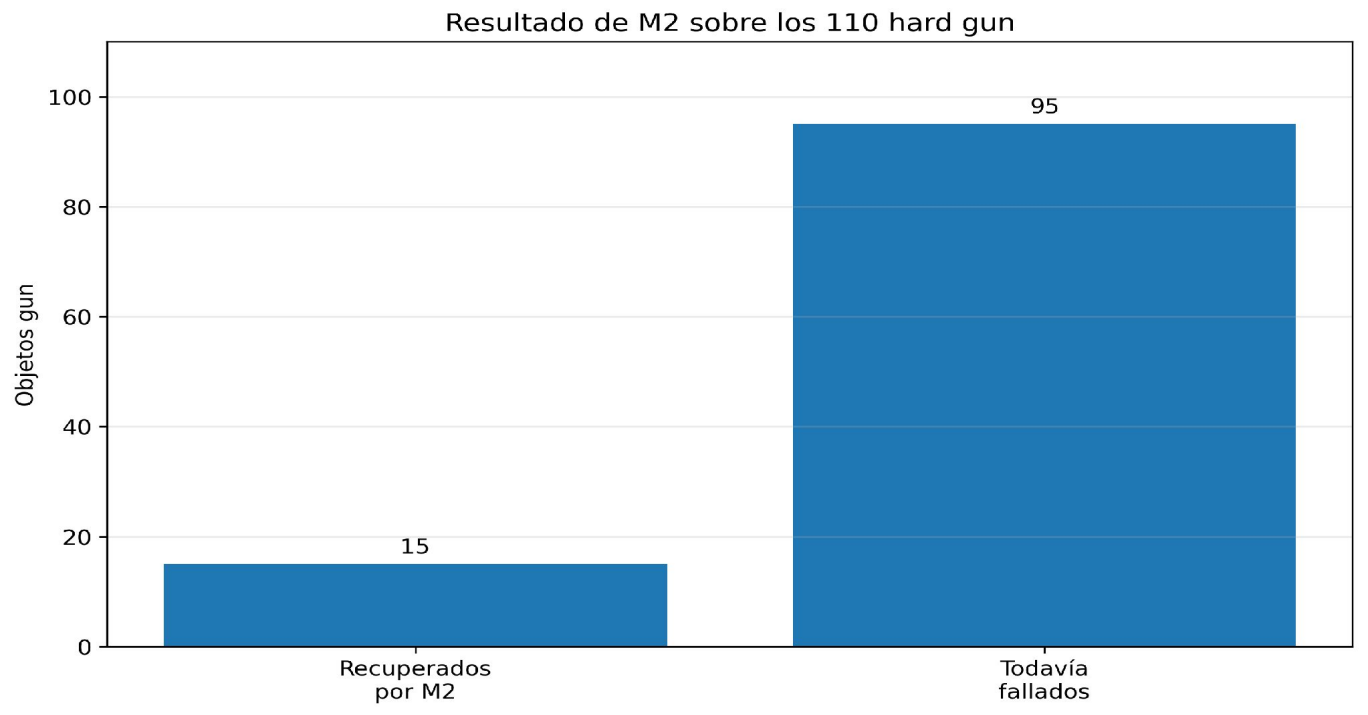


Lectura

B1 varía 0.018 entre corridas; la ventaja inicial de M2 fue 0.011. Misma semilla 0 en otra GPU: el orden entre B1 y M2 se invierte. La caída de M1 sí es robusta.

Multi-Scale no resolvió todos los casos difíciles

La mejora fue real en el protocolo diagnóstico, pero quedaron objetos extremadamente pequeños sin detectar.



15 / 110 recuperados

M2 detectó el 13.64% de los objetos que B1 y M1 fallaron.

95 / 110 persistieron

El límite principal siguió siendo el tamaño aparente extremo.

Advertencia: con confidence 0.001, M2 tuvo más FP diagnósticos que B1; no son las Precision oficiales.

GENERALIZACIÓN

Test independiente: checkpoint M2 congelado

508 imágenes · 1,288 objetos · Test no intervino en la selección de B1, M1 o M2.

0.845
mAP@0.5 global · Test

0.659
mAP@0.5:0.95 global

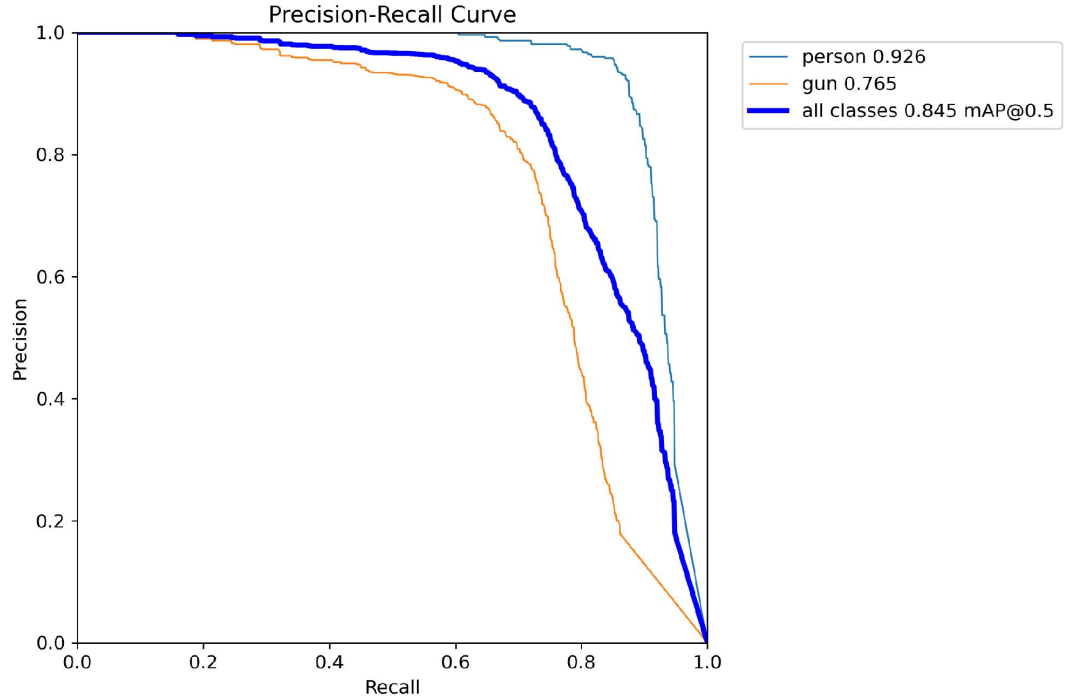
0.697
Recall de gun · Test

Clase	Precision	Recall	mAP@.5	mAP@.5:.95
Global	0.875	0.780	0.845	0.659
person	0.933	0.863	0.926	0.812
gun	0.817	0.697	0.765	0.506

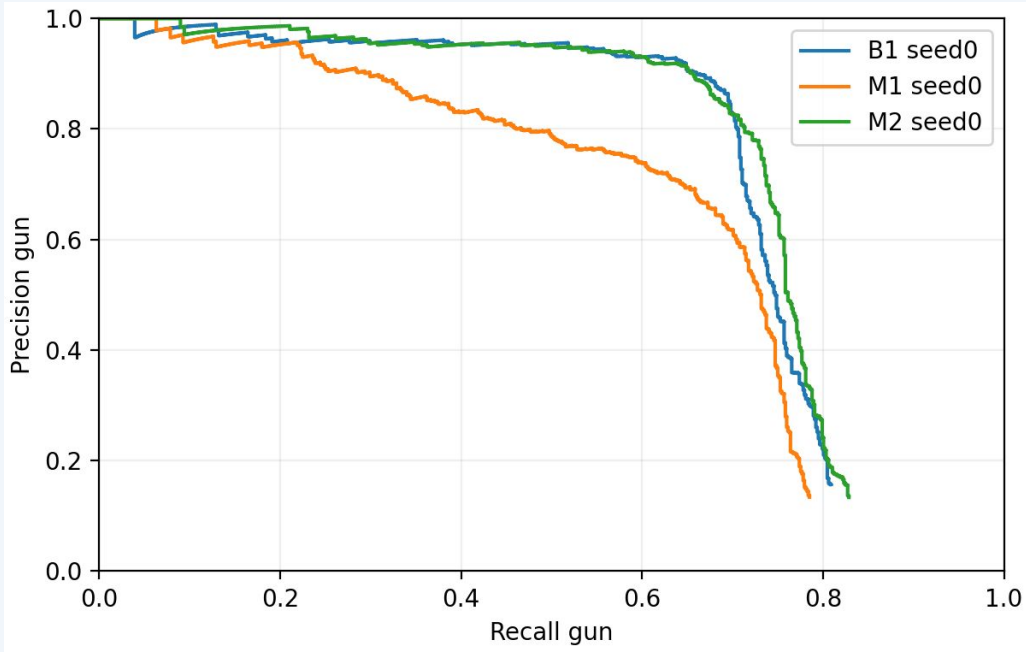
La clase gun sigue siendo más difícil; los resultados no justifican un uso autónomo del detector.

Curvas Precision–Recall sobre Test y Validation

El comportamiento de gun es inferior al de person, especialmente para niveles exigentes de recuperación.



Test · PR por clase (M2)

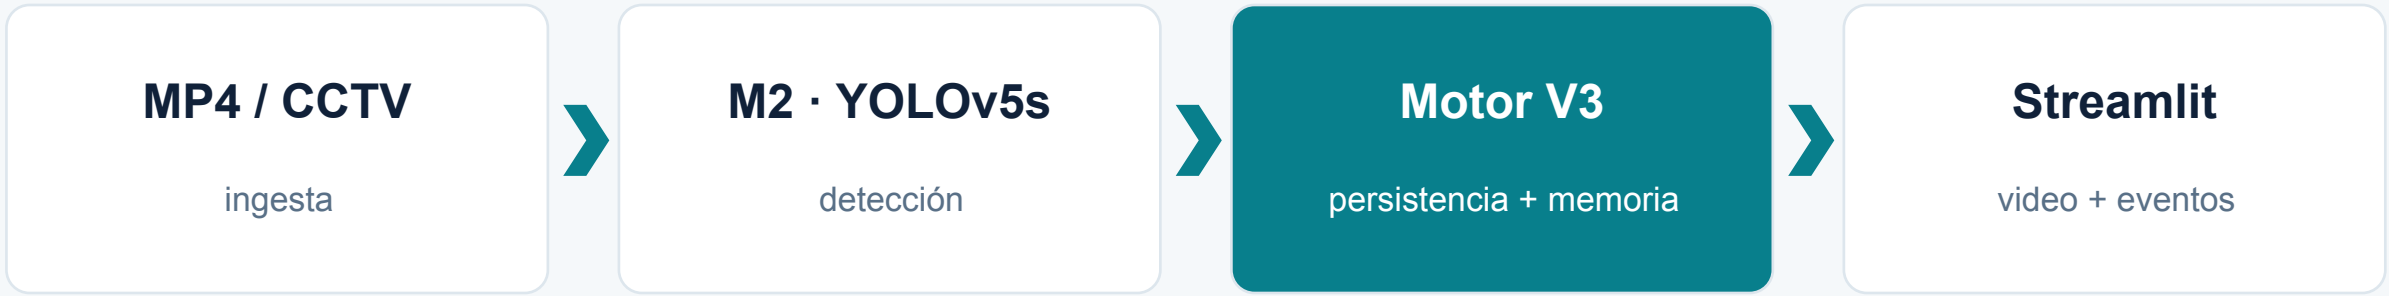


Validation · PR de gun (B1, M1, M2)

MVP

AI Security Monitoring System

Prueba de concepto en Streamlit: del detector por frame a la priorización temporal de eventos.



INFO → ALERT → CRITICAL

Registro de persona, detección de arma y coexistencia operacional para priorizar revisión.

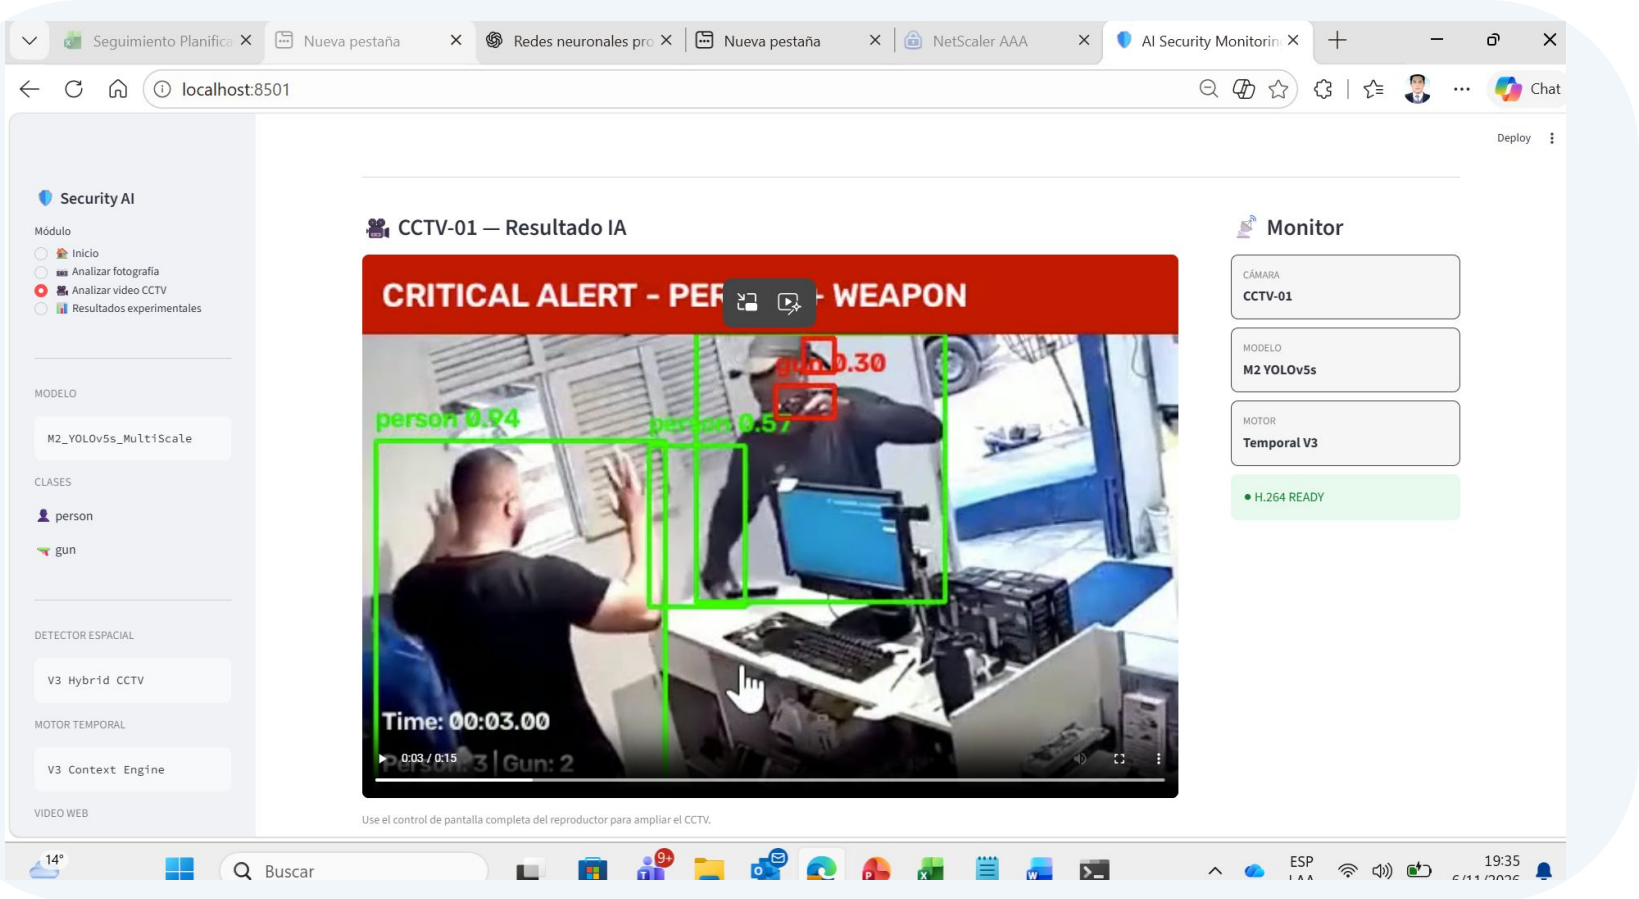
Alcance del prototipo

Interfaz y archivo de eventos; no identifica culpables ni confirma que una persona porte un arma.

SOFTWARE DESARROLLADO

MVP en funcionamiento: interfaz Streamlit

Captura real de AI Security Monitoring System incluida en el artículo IEEE.



Del frame al evento

1. Entrada de video
2. Modelo M2
3. Motor temporal V3
4. Alerta prioritaria
5. Revisión humana

La alerta CRITICAL señala coexistencia operacional, no autoría ni intención.

Evolución del motor temporal V1–V5

Reglas de postprocesamiento sobre las detecciones M2; no son cinco nuevas redes entrenadas.

V1	Persistencia temporal	
V2	Consistencia espacial (IoU)	
V3	**Memoria para oclusiones**	CONFIGURACIÓN OPERATIVA
V4	Seguimiento y movimiento	
V5	Filtrado de fondo estático	

Las versiones más restrictivas redujeron confirmaciones, con posible pérdida de sensibilidad.

Comparación operativa del motor V3, V4 y V5

Un único video CCTV de 2,836 frames; valores de una ejecución concreta, sin ground truth temporal formal.

Indicador	V3	V4	V5
Ciclos IA	473	473	473
Confirmaciones motor	66	14	1
Memoria / oclusión	41	10	0
Alertas críticas	25	4	1
Eventos contabilizados	7	3	1
Tiempo (s)	259.86	381.41	506.73
Velocidad (fps)	10.91	7.44	5.60

V3 conserva más confirmaciones y velocidad; estos recuentos NO equivalen a TP/FP verificados.

DISCUSIÓN

Limitaciones, reproducibilidad y responsabilidad

Resultados útiles para investigación, no para decisiones automáticas en entornos de seguridad.

Limitaciones del detector

Recall gun en Test: 0.697.
Sensibilidad a escala, perspectiva, iluminación y domain shift.
Solo seed 0 para comparación principal.

Reproducibilidad

YOLOv5 v7.0 · SGD · 100 épocas.
GPU NVIDIA A100.
Checkpoint M2 con SHA256.
Código y gráficas en repositorio.

Uso responsable

Revisión humana obligatoria.
No inferir intención ni identidad.
Privacidad de video, acceso, auditoría y pruebas del dominio.

Siguiente paso: hard negatives de CCTV, datos difíciles y evaluación temporal con anotaciones independientes.

CONCLUSIONES

Una mejora fundamentada en evidencia

01

Más resolución no bastó

M1 fue más costoso y rindió menos.

02

Multi-Scale aportó

M2 redujo FN gun 132 → 122 en Validation.

03

El video exige contexto

V3 añade memoria temporal para apoyar revisión.

Gracias · Preguntas